### Проектная работа на тему: Сбор и обработка данных по валютам с помощью ClickHouse.

Система ежедневно получает данные с сайта банка России по арі в формате xml: https://www.cbr.ru/development/SXML/

# 1. Сборка компонентов для получения и хранения данных.

Переходим в папку проекта - OtusClickHouse-Project\.

Собираем и запускаем контейнер PostgreSQL с помощью скрипта docker/build\_docker\_postgres.sh.

build\_docker\_postgres.sh:

```
#!/bin/bash
docker stop postgresql
docker rm postgresql \
docker run --name postgresql \
-e POSTGRES_PASSWORD=passwordpg1234 \
-e POSTGRES_USER=userpg \
-e POSTGRES_DB=pgdb \
-p 5433:5432 \
-v "./postgresql/data":"/var/lib/postgresql/data" \
-d postgres:latest
```

Подключаемся к базе и создаем схему с таблицей:

```
CREATE SCHEMA pgclick;
CREATE TABLE IF NOT EXISTS pgclick.valute data(
      id bigint NOT NULL PRIMARY KEY,
      date VARCHAR(36) NOT NULL,
      name VARCHAR(200) NOT NULL,
      str_id VARCHAR(20) NOT NULL,
      num code VARCHAR(20) NOT NULL,
      char code VARCHAR(20) NOT NULL,
      nominal VARCHAR(20) NOT NULL,
      value VARCHAR(50) NOT null
);
CREATE UNIQUE INDEX idx valute pk
ON pgclick.valute data(id);
CREATE UNIQUE INDEX idx valute data
ON pgclick.valute_data(date, str_id);
CREATE SEQUENCE IF NOT EXISTS pgclick.seq valute id;
```

Собираем приложение xml-parser с помощью скрипта xml-parser/build\_app.sh. Для сборки потребуется установленный maven. Docker-контейнер собираем и запускаем с помощью скрипта xml-parser/build\_docker.sh.

- build app.sh:

```
#!/bin/bash
git pull
mvn clean install
```

# - build\_docker.sh:

#!/bin/bash

docker build -f app.Dockerfile -t uoles/xml-parser:1.0.1.

docker stop xml-parser docker rm xml-parser

docker run -d --name xml-parser \
 --network=host \
 --publish 8090:8090 \
 uoles/xml-parser:1.0.1

app.Dockerfile:

FROM docker.io/library/openjdk:17 MAINTAINER Maksim Kulikov <max.uoles@rambler.ru>

COPY target/xml-parser.jar xml-parser.jar

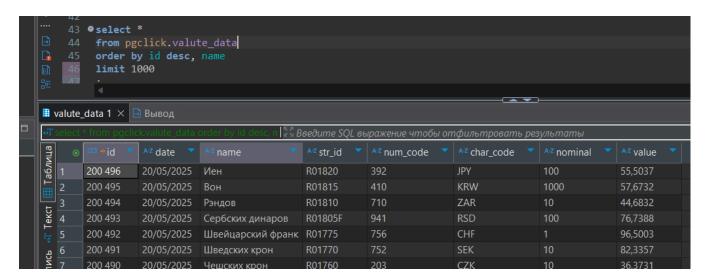
ENV TZ=Europe/Moscow

RUN ln -snf /usr/share/zoneinfo/\$TZ /etc/localtime && echo \$TZ > /etc/timezone

EXPOSE 8090

CMD ["java","-jar","xml-parser.jar"]

После запуска базы и приложения начинается сбор данных с 1 декабря 2010 года по текущее время. Так же, ежедневно в 12:30 подгружаются данные на текущие сутки.



### 2. Сборка компонентов для обработки данных.

Переходим в каталог OtusClickHouse-Project\docker и запускаем сборку docker-compose.yml, в котором запускаются clickhouse, kafka и superset.

```
Для этого выполняем команду: docker-compose up -d
Superset - http://localhost:8088
Kafka-ui – http://localhost:8089
docker-compose.yml:
x-superset-image: &superset-image apache/superset:${TAG:-latest-dev}
x-superset-depends-on: & superset-depends-on
 - db
 - redis
x-superset-only-depends-on: & superset-only-depends-on
 - db
 - redis
 - clickhouse-server
x-superset-volumes: & superset-volumes
 - ./docker:/app/docker
 - superset_home:/app/superset_home
version: "3.7"
services:
 clickhouse-server:
  container_name: clickhouse-server
  image: uoles/clickhouse:25.2.1
  build:
   context: .
   dockerfile: clickhouse-25.2.1.Dockerfile
  environment:
   CLICKHOUSE_DB: my_database
   CLICKHOUSE USER: username
   CLICKHOUSE_DEFAULT_ACCESS_MANAGEMENT: 1
   CLICKHOUSE_PASSWORD: password
  ports:
   - "18123:8123"
   - "19000:9000"
  volumes:
   - ./clickhouse/config.xml:/etc/clickhouse-server/config.xml
   - ./clickhouse/zookeeper-servers.xml:/etc/clickhouse-server/conf.d/zookeeper-servers.xml
  ulimits:
   nofile:
    soft: 262144
    hard: 262144
  depends_on:
   - kafka
  links:
   - kafka
 zookeeper:
  container_name: zookeeper
  image: confluentinc/cp-zookeeper:6.2.4
  healthcheck:
   test: [ "CMD", "nc", "-vz", "localhost", "2181" ]
   interval: 10s
   timeout: 3s
   retries: 3
```

environment:

```
ZOOKEEPER CLIENT PORT: 2181
   ZOOKEEPER_TICK_TIME: 2000
  ports:
   - 22181:2181
kafka:
  container name: kafka
 image: confluentinc/cp-kafka:6.2.4
 depends_on:
   zookeeper:
    condition: service_healthy
  ports:
   - "29092:29092"
   - "29093:29093"
 healthcheck:
   test: [ "CMD", "nc", "-vz", "localhost", "9092" ]
   interval: 10s
   timeout: 3s
   retries: 3
  environment:
   KAFKA BROKER ID: 1
   KAFKA_ZOOKEEPER_CONNECT: zookeeper:2181
   KAFKA_LISTENERS: OUTSIDE://:29092,INTERNAL://:9092,EXTERNAL_DIFFERENT_HOST://:29093
   KAFKA_ADVERTISED_LISTENERS:
OUTSIDE://localhost:29092,INTERNAL://kafka:9092,EXTERNAL_DIFFERENT_HOST://89.169.3.137:29093
   KAFKA_LISTENER_SECURITY_PROTOCOL_MAP:
INTERNAL:PLAINTEXT,OUTSIDE:PLAINTEXT,EXTERNAL_DIFFERENT_HOST:PLAINTEXT
   KAFKA_INTER_BROKER_LISTENER_NAME: INTERNAL
   KAFKA_OFFSETS_TOPIC_REPLICATION_FACTOR: 1
kafka-ui:
  image: provectuslabs/kafka-ui
 container_name: kafka-ui
 ports:
   - "8089:8080"
 restart: always
 depends_on:
   kafka:
    condition: service healthy
  environment:
   KAFKA_CLUSTERS_0_NAME: local
   KAFKA_CLUSTERS_0_BOOTSTRAPSERVERS: kafka:9092
redis:
 image: redis:7
 container name: superset cache
 restart: unless-stopped
 volumes:
   - redis:/data
 db:
 env file: docker/.env-non-dev
 image: postgres:14
 container name: superset db
 restart: unless-stopped
  volumes:
   - db_home:/var/lib/postgresql/data
 superset:
 env file: docker/.env-non-dev
```

image: \*superset-image

```
container_name: superset_app
  command: [sh, -c, "pip install clickhouse-connect && /app/docker/docker-bootstrap.sh app-gunicorn"]
  user: "root"
  restart: unless-stopped
  ports:
   - 8088:8088
  depends on: *superset-only-depends-on
  volumes: *superset-volumes
  links:
   - clickhouse-server
 superset-init:
  image: *superset-image
  container_name: superset_init
  command: [ "/app/docker/docker-init.sh" ]
  env_file: docker/.env-non-dev
  depends_on: *superset-depends-on
  user: "root"
  volumes: *superset-volumes
  healthcheck:
   disable: true
 superset-worker:
  image: *superset-image
  container_name: superset_worker
  command: [ "/app/docker/docker-bootstrap.sh", "worker" ]
  env_file: docker/.env-non-dev
  restart: unless-stopped
  depends_on: *superset-depends-on
  user: "root"
  volumes: *superset-volumes
  healthcheck:
   test: [ "CMD-SHELL", "celery inspect ping -A superset.tasks.celery_app:app -d celery@$$HOSTNAME" ]
 superset-worker-beat:
  image: *superset-image
  container_name: superset_worker_beat
  command: [ "/app/docker/docker-bootstrap.sh", "beat" ]
  env file: docker/.env-non-dev
  restart: unless-stopped
  depends_on: *superset-depends-on
  user: "root"
  volumes: *superset-volumes
  healthcheck:
   disable: true
volumes:
 superset_home:
  external: false
 db_home:
  external: false
 redis:
  external: false
```

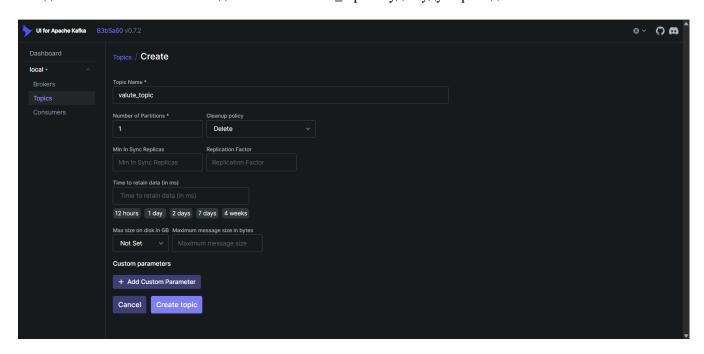
- Подключаемся к clickhouse и проливаем таблицы и вьюхи:

```
CREATE TABLE valute_data
      id UInt64,
    date Date,
   name String,
    str_id String,
   num_code String,
    char_code String,
    nominal UInt32,
    value Float32
ENGINE = MergeTree
ORDER BY (id, date, str_id);
CREATE TABLE valute_data_queue
      id UInt64,
    date String,
    name String,
    str_id String,
    num_code String,
    char_code String,
    nominal String,
    value String
ENGINE = Kafka
SETTINGS
    kafka_broker_list = 'kafka:9092',
    kafka_topic_list = 'valute_topic',
    kafka_group_name = 'valute_group',
    kafka_format = 'JSONEachRow',
      kafka_row_delimiter = '\n',
    kafka_num_consumers = 1,
    kafka_skip_broken_messages = 10,
    kafka_thread_per_consumer = 0;
CREATE MATERIALIZED VIEW valute data queue mv TO valute data
      id UInt64,
    date Date,
    name String,
    str_id String,
    num_code String,
    char_code String,
    value Float32
SELECT
      parseDateTimeBestEffortOrNull(date, 'Europe/Moscow') AS date,
      str_id,
      num_code,
      toInt320rNull(nominal) as nominal,
      toFloat320rNull(replaceOne(value, ',', '.')) / nominal as value
FROM valute_data_queue
WHERE name not in ('Евро', 'Дирхам ОАЭ', 'Тенге');
```

```
CREATE MATERIALIZED VIEW valute data evro mv TO valute data evro
      id UInt64,
    name String,
    str_id String,
    num_code String,
    char_code String,
    value Float32
SELECT
      parseDateTimeBestEffortOrNull(date, 'Europe/Moscow') AS date,
      str_id,
      num_code,
      char_code,
      toInt320rNull(nominal) as nominal,
      toFloat320rNull(replaceOne(value, ',', '.')) / nominal as value
FROM valute_data_queue
WHERE name = 'Eвро';
CREATE TABLE valute_data_evro
      id UInt64,
    date Date,
    name String,
    str_id String,
    num_code String,
    char_code String,
ENGINE = MergeTree
ORDER BY (id, date, str_id);
CREATE MATERIALIZED VIEW valute_data_dirham_mv TO valute_data_dirham
    id UInt64,
    date Date,
    name String,
    str_id String,
    num_code String,
    char_code String,
    nominal UInt32,
    value Float32
) AS
SELECT
      parseDateTimeBestEffortOrNull(date, 'Europe/Moscow') AS date,
      num code,
      char_code,
      toInt320rNull(nominal) as nominal,
      toFloat320rNull(replaceOne(value, ',', '.')) /nominal as value
FROM valute_data_queue
WHERE name = 'Дирхам ОАЭ';
CREATE TABLE valute_data_dirham
      id UInt64,
    date Date,
    name String,
    str_id String,
```

```
num_code String,
    char_code String,
    value Float32
ENGINE = MergeTree
ORDER BY (id, date, str_id);
CREATE MATERIALIZED VIEW valute_data_tenge_mv TO valute_data_tenge
      id UInt64,
    date Date,
    name String,
    str_id String,
    num_code String,
    char_code String,
    value Float32
SELECT
       id,
      parseDateTimeBestEffortOrNull(date, 'Europe/Moscow') AS date,
      num_code,
      char_code,
      toInt32OrNull(nominal) as nominal,
      toFloat320rNull(replaceOne(value, ',', '.')) /nominal as value
FROM valute_data_queue
WHERE name = 'Тенге';
CREATE TABLE valute_data_tenge
      id UInt64,
    date Date,
    name String,
    str_id String,
    num_code String,
    char_code String,
    value Float32
ENGINE = MergeTree
ORDER BY (id, date, str_id);
```

- Подключаемся к kafka-ui и создаем топик "valute\_topic" куда будут приходить обновления от debezium:



Теперь kafka и clickhouse могут принимать данные.

# 3. Настраиваем PostgreSQL и разворачиваем приложение с компонентом debezium.

Подключаемся к ранее развернутому контейнеру PostgreSQL и подготавливаем ее к подключению приложения. Для этого нужно выставить:

- уровень репликации "logical" и перезапустить базу;
- создать публикацию, с описанием таблиц и операций, которые будем обрабатывать;
- нужен пользователь со свойством REPLICATION (есть по умолчанию у пользователя при создании контейнера).

### Скрипты:

```
ALTER SYSTEM_SET_wal level = logical;

SHOW wal_level; -- проверяем уровень репликации после рестарта

CREATE PUBLICATION pgclick_publication
    FOR TABLES IN SCHEMA pgclick
    with(publish = 'insert');
```

Для запуска приложения переходим в каталог OtusClickHouse-Project\debezium\. Так же, как и xml-parser собираем и разворачиваем debezium скриптами build\_app.sh и build\_docker.sh.

- build\_app.sh:

#!/bin/bash git pull mvn clean install

- build docker.sh:

```
#!/bin/bash
docker build -f app.Dockerfile -t uoles/debezium:1.0.1 .

docker stop debezium
docker rm debezium

docker run -d --name debezium \
    --network=host \
    --publish 8091:8091 \
    uoles/debezium:1.0.1
```

FROM docker.io/library/openjdk:17 MAINTAINER Maksim Kulikov <max.uoles@rambler.ru>

COPY target/debezium.jar debezium.jar

app.Dockerfile:

EXPOSE 8091

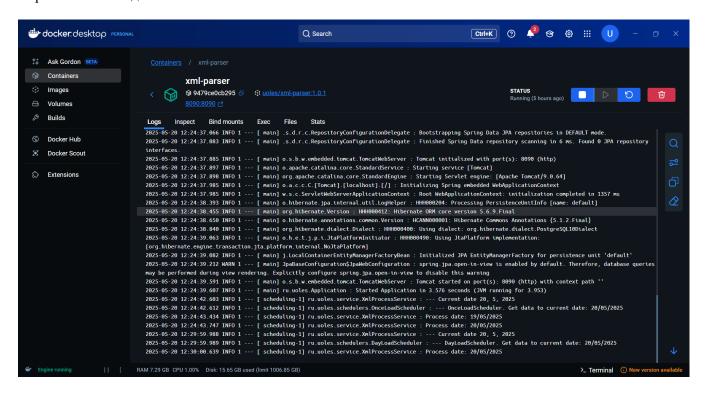
CMD ["java","-jar","debezium.jar"]

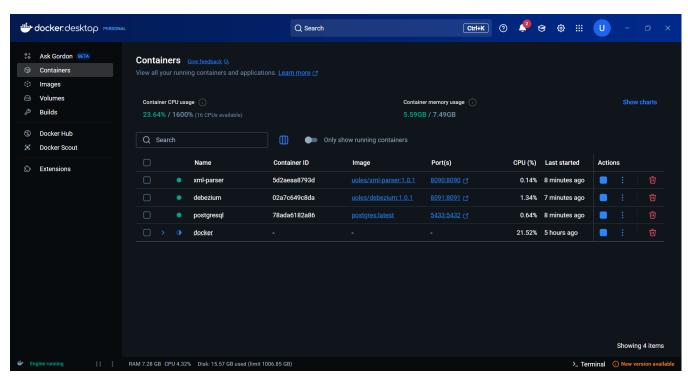
Приложение подключается к бд PostgreSQL, получает все изменения в базе из wal-журнала через библиотеку debezium и отправляет данные в kafka в формате json.

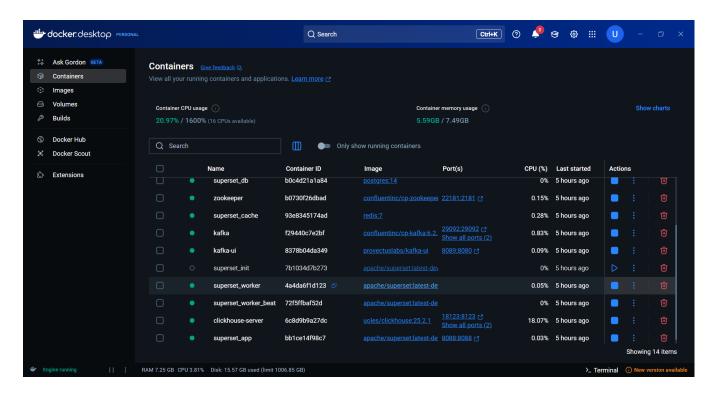
## Конфигурация debezium:

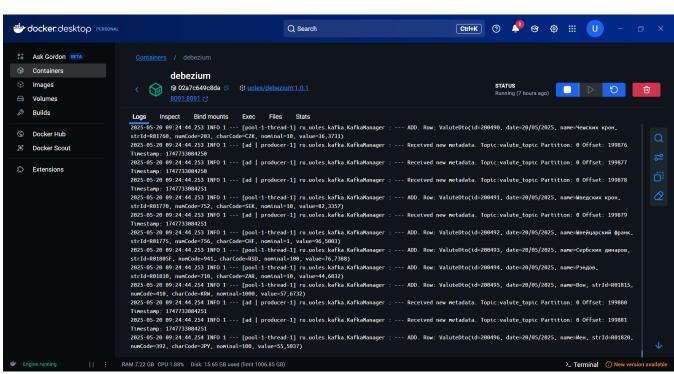
```
# Jiminganer | ImminganerapppDockerfile | ImminganerappDockerfile | AppConfigjana | DebeaumConfigjana | De
```

#### Скрины логами и данными:

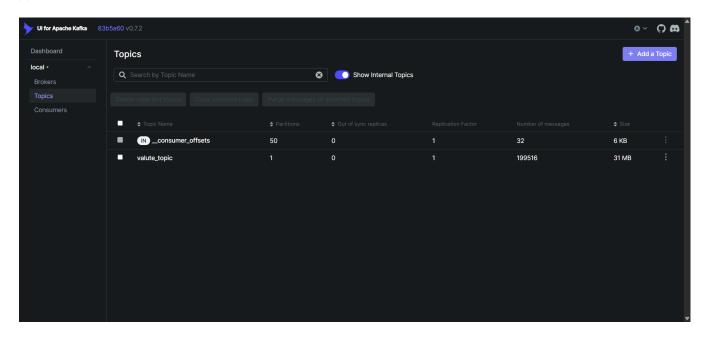


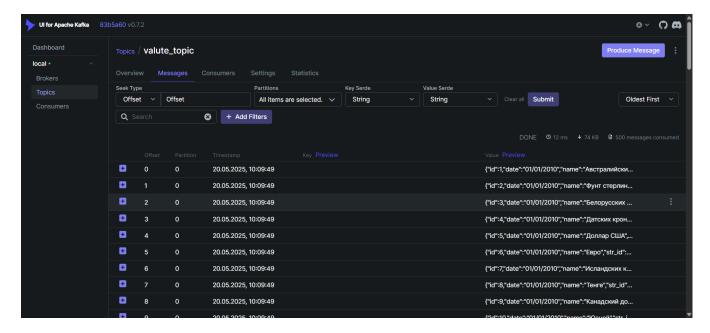




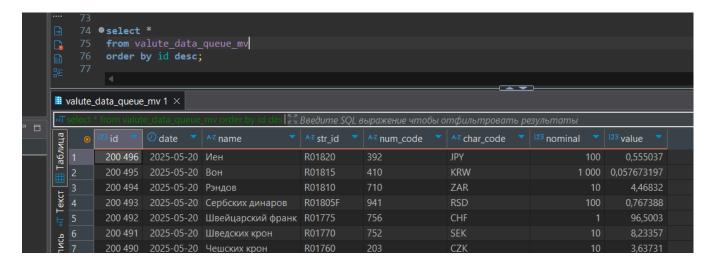


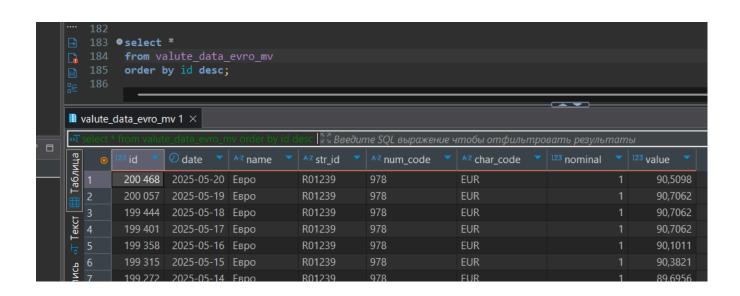
# Данные в топике kafka-ui:

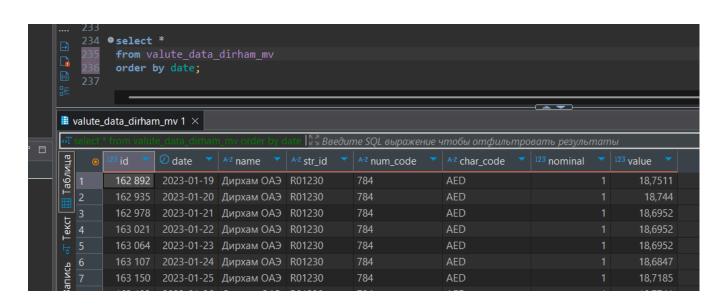


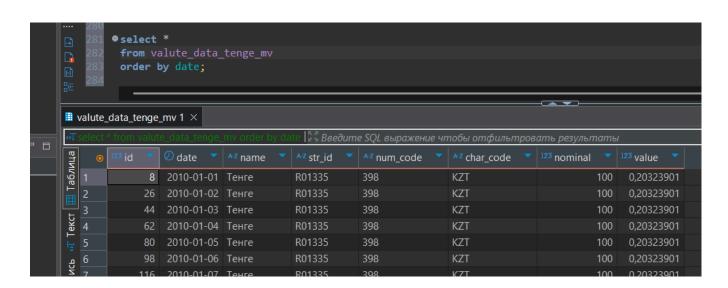


### Данные в clickhouse:









# 4. Создание графиков.

После разворачивания инфраструктуры заходим в Superset и создаем графики.

# Графики с отдельными вьюхами:

- курс Евро с 2010 года;
- курс Тенге с 2010 года;
- курс Дирхам ОАЭ с 2010 года;

# Графики на общей вьюхе:

- курсы Доллара США и Австралийского доллара;
- курс Вон, минимальный и максимальные значения за месяц;
- курсы Норвежской кроны, Датской кроны и Белорусских рублей.

